Influência do Tamanho e da Sobreposição de *Chunks* na Recuperação e na Fidelidade de um Sistema RAG sobre Material Didático

Gustavo Xavier Evangelista
FCTE – Universidade de Brasília
Brasília, Brasil
241025247@aluno.unb.br

Heitor Macêdo Ricardo
FCTE – Universidade de Brasília
Brasília, Brasil
241039073@aluno.unb.br

***Resumo*—A divisão de documentos em trechos altera tanto a evidência recuperada quanto o contexto entregue a sistemas de geração aumentada por recuperação (RAG). Comparamos uma segmentação estrutural por slide e janelas de 128, 256 e 512 tokens, com 0 ou 20 % de sobreposição, em 45 perguntas sobre 10 aulas em português. O recuperador, o gerador Qwen2.5-3B-Instruct e o orçamento de cinco trechos foram mantidos fixos. A segmentação por slide apresentou MRR@5 de 0,87, enquanto a janela de 512 tokens sem sobreposição apresentou Recall@5 de 0,94; esta última usou 3061 tokens de entrada do gerador em média, contra 1113 com slides. As diferenças observadas entre 20 % e 0 % de sobreposição mudaram de sinal ou magnitude entre os tamanhos, sem indicar uma vantagem consistente. As conclusões se restringem a este corpus, ao gerador de 3 bilhões de parâmetros e a $k = 5$; os julgamentos automáticos de qualidade são apresentados como análise de sensibilidade.**

***Palavras-chave*—geração aumentada por recuperação, *chunking*, recuperação de informação, fidelidade, modelos de linguagem**

I. Introdução

RAG condiciona um modelo de linguagem a trechos recuperados de uma base externa, permitindo respostas apoiadas em fontes [1]. A segmentação define a unidade indexada e o conteúdo que chega ao gerador. Trechos pequenos podem fragmentar explicações; trechos grandes aumentam o contexto e podem reduzir o foco semântico. Estudos de granularidade confirmam que a unidade de recuperação afeta tarefas de busca e resposta [2].

Slides oferecem uma linha de base natural: cada página costuma reunir um conceito, mas explicações podem atravessar páginas. Perguntamos: *como tamanho e sobreposição dos trechos influenciam a recuperação de páginas-evidência, a verificabilidade e o custo de um RAG sobre slides em português?* Comparamos 7 configurações sob o mesmo protocolo e publicamos o conjunto de perguntas com evidências por página [3].

II. Trabalhos Relacionados

O RAG original combinou recuperação densa e geração [1]; o DPR consolidou o uso de codificadores duplos para busca de passagens [4]. O E5 multilíngue fornece *embeddings* para consultas e passagens [5], [6], e o FAISS permite busca exata por produto interno [7]. Dense X Retrieval mostrou que a granularidade indexada influencia a recuperação e a resposta sob um orçamento fixo [2]. *Lost in the Middle* identificou efeitos de posição em contextos longos, mas não estabelece, por si só, que todo trecho longo reduz qualidade [8].

RAGAS organiza dimensões de avaliação automática de RAG [9]. Modelos usados como juízes podem reproduzir preferências e vieses; sua concordância não substitui validação humana [10], [11]. Por isso, tratamos os julgamentos automáticos disponíveis como sensibilidade e evitamos atribuir causalmente cada erro ao recuperador ou ao gerador.

III. Metodologia

A. Corpus, perguntas e configurações

O corpus contém 482 páginas das aulas 14 a 23 [12]. O conjunto tem 60 perguntas: 15 de desenvolvimento e 45 de teste; no teste, 41 são respondíveis e 4 não têm resposta no material. As evidências são pares (aula, página), definidas antes do teste. O texto foi extraído página a página, com recomposição de caracteres separados e remoção de rodapé repetido. Cada registro conserva o número da aula, a página e o hash do PDF de origem; páginas com pouco texto são sinalizadas para revisão, pois fórmulas e diagramas podem não ser recuperados pela extração textual. As perguntas foram distribuídas entre factual, contextual, multitrecho e não respondível. Uma resposta factual ou contextual pode aceitar páginas alternativas; uma pergunta multitrecho enumera páginas conjuntamente necessárias. Essa distinção impede que recuperar uma única parte de uma explicação composta seja contabilizado como cobertura completa.

A configuração `slide` indexa uma página por trecho. As demais combinam 128, 256 e 512 tokens com 0 ou 20 % de sobreposição, sem atravessar aulas. Todas usam o E5 multilíngue base na revisão congelada d128750, com os prefixos recomendados e vetores normalizados [6]. O k foi selecionado no desenvolvimento entre 1, 3 e 5; o maior Recall médio resultou em $k = 5$.

O gerador é o Qwen2.5-3B-Instruct de 3,09 bilhões de parâmetros, revisão aa8e725, em FP16 numa T4, com decodificação gulosa e até 256 novos tokens [13], [14]. O *prompt*

exige citações no formato $[n]$ e uma frase fixa de abstenção. Cada configuração recebe a mesma pergunta, o mesmo limite de saída e os cinco primeiros trechos de seu próprio ranking. Não há amostragem na decodificação; diferenças entre configurações decorrem do contexto recuperado e da maneira como o modelo determinístico reage a ele. O tempo é medido ao redor da preparação e da chamada do gerador depois que os modelos e índices já foram carregados, evitando misturar inicialização com inferência.

B. Métricas e análise

Recall@5 é a fração das páginas anotadas cobertas pelos cinco trechos; MRR@5 usa a posição da primeira evidência. Para itens factuais e contextuais, páginas anotadas alternativas definem sucesso@5 quando ao menos uma é recuperada. Para itens multitrecho, sucesso@5 exige todas as páginas obrigatórias; Multi@5 registra essa cobertura no subconjunto multitrecho. As métricas de recuperação usam somente as 41 perguntas respondíveis.

Cobertura de citação é a fração das respostas respondíveis não abstidas que contêm citação. Relevância de citação é calculada apenas nas respostas com ao menos uma citação válida e mede a fração de trechos citados que cobre página-evidência. Os tokens medem a entrada completa do gerador. A latência inclui montagem e tokenização do *prompt*, geração e decodificação; exclui busca e carregamento dos modelos. O F1 lexical publicado originalmente permanece no CSV para rastreabilidade, mas foi retirado da tabela por não medir adequadamente correção semântica.

Para cada tamanho, a análise de sobreposição compara 20 % contra 0 % na mesma pergunta. Se $m_{q,c}$ é a métrica da pergunta q na configuração c, o estimando é a média de $m_{q,t,20} - m_{q,t,0}$ para um tamanho t fixo. O *bootstrap* reamostra identificadores de pergunta, preservando o par em cada réplica; o intervalo percentil de 95 % usa 10.000 réplicas. Esse desenho estima a diferença observada no conjunto de perguntas e não um efeito causal da sobreposição, pois tamanho, posição das fronteiras e redundância dos slides interagem com o conteúdo. O protocolo completo prevê *bootstrap* pareado por pergunta e avaliação humana independente, cega à configuração, seguida de kappa ponderado e consenso. Como os rankings individuais, as 315 respostas e as planilhas humanas não estavam no pacote versionado, esta revisão não fabrica esses intervalos ou escores: apresenta os agregados recuperáveis e mantém a análise automática anterior apenas como sensibilidade. Os resultados antigos são preservados; o código valida o commit experimental `4f347d6`, os hashes, a grade e k antes de aceitar uma reconstrução.

IV. Resultados

A Tabela I reorganiza os agregados disponíveis, retirando R@1, P@5 e F1.

Slides obtiveram o maior MRR@5 (0,87, IC [0,77; 0,95]). A janela de 512 tokens sem sobreposição obteve o maior Recall@5 (0,94), com diferença de 0,06 contra slides (IC [−0,01; 0,15]), mas MRR@5 −0,10 menor (IC [−0,21; 0,02]). Essas comparações descrevem valores observados e incerteza contra a linha de base; não demonstram equivalência.

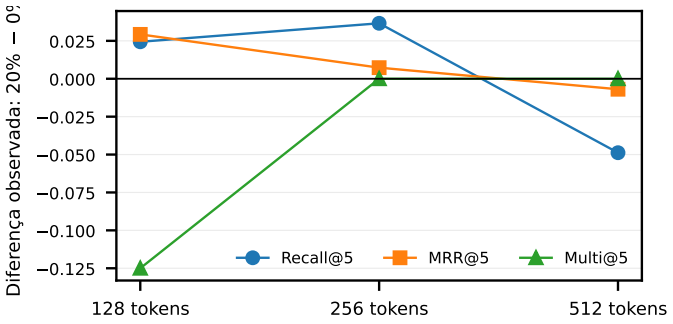


Fig. 1. Diferenças observadas entre 20 % e 0 % de sobreposição no mesmo tamanho. Pontos acima de zero favorecem 20 %; não há intervalos porque os rankings individuais não estavam no pacote versionado.

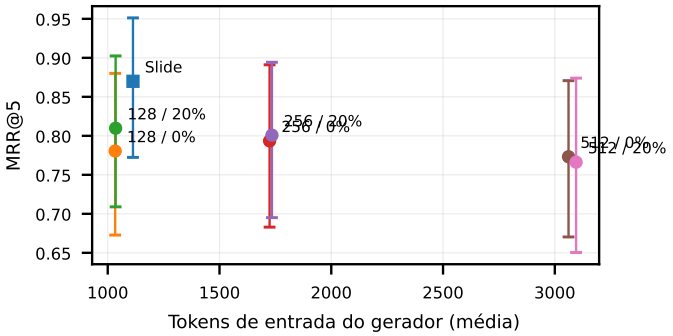


Fig. 2. MRR@5 e IC de 95 % por *bootstrap* de perguntas contra a média de tokens de entrada do gerador. Os intervalos são marginais; não testam a diferença entre configurações.

A Fig. 1 compara diretamente sobreposição dentro de cada tamanho. Os pontos não seguem direção única: o ganho observado de Recall@5 nas janelas de 128 e 256 tokens não se repete em 512 tokens, e Multi@5 cai em 128 tokens. Sem os rankings por pergunta, não se atribui intervalo pareado a esses pontos nem efeito causal à sobreposição. Em 128 tokens, Recall@5 passa de 0,89 para 0,91 e MRR@5 de 0,78 para 0,81, enquanto Multi@5 passa de 0,62 para 0,50. Em 256 tokens, os valores passam de 0,89 para 0,93 em Recall@5 e de 0,79 para 0,80 em MRR@5, com Multi@5 igual a 0,62 nas duas condições. Em 512 tokens, Recall@5 cai de 0,94 para 0,89, MRR@5 permanece em 0,77 após arredondamento e Multi@5 permanece em 0,62. O padrão não autoriza selecionar uma porcentagem de sobreposição independente do tamanho.

O custo cresce com o tamanho: 512/0 usa 3061 tokens de entrada e 10,8 s, ante 1113 e 6,1 s com slides. Esse aumento inclui mais texto no *prompt* e maior trabalho de geração, mas não mede a busca vetorial; portanto, não representa a latência ponta a ponta de um serviço RAG. Na Fig. 2, os intervalos marginais de MRR@5 se sobrepõem, enquanto o eixo de custo separa as janelas de 512 tokens das demais configurações.

Todas as configurações se abstiveram corretamente nos 4 itens não respondíveis. A cobertura de citação variou de 82%

Tabela I
RESULTADOS DISPONÍVEIS POR CONFIGURAÇÃO (TAMANHO/SOBREPOSIÇÃO). R@5 E MRR@5: 41 PERGUNTAS; MULTI@5: SUBCONJUNTO MULTITRECHO; COB. CIT.: RESPOSTAS RESPONDÍVEIS NÃO ABSTIDAS; REL. CIT.: SOMENTE RESPOSTAS COM CITAÇÃO VÁLIDA; CORR., FID. E N. SUST.: ANÁLISE DE SENSIBILIDADE POR DOIS JUÍZES AUTOMÁTICOS, RESPECTIVAMENTE EM $[0, 1]$, $[0, 1]$ E ESCALA TRUNCADA 0–3; TOK. ENT.: TOKENS DE ENTRADA DO GERADOR.

Config.	R@5	MRR@5	Multi@5	Cob. cit.	Rel. cit.	Corr.	Fid.	N. sust.	Tok. ent.	Lat. (s)
Slide	0,88	**0,87**	0,50	95%	0,79	**0,70**	0,85	0,45	1113	6,1
128 / 0%	0,89	0,78	**0,62**	95%	0,76	0,65	0,82	0,55	**1033**	**5,6**
128 / 20%	0,91	0,81	0,50	95%	**0,80**	0,65	0,90	0,30	1035	6,2
256 / 0%	0,89	0,79	**0,62**	93%	0,71	0,68	**0,93**	**0,20**	1724	7,1
256 / 20%	0,93	0,80	**0,62**	**98%**	0,74	**0,70**	0,90	0,40	1735	6,8
512 / 0%	**0,94**	0,77	**0,62**	90%	0,48	0,62	0,88	0,50	3061	10,8
512 / 20%	0,89	0,77	**0,62**	82%	0,64	0,68	0,85	0,50	3095	11,3

em 512/20 a 98% em 256/20. A relevância das citações foi 0,79 com slides e 0,48 com 512/0; essa métrica não deve ser confundida com P@5 nem com cobertura de citação. P@5 divide o número de trechos recuperados que cobrem uma página-evidência por cinco, independentemente do que o gerador cita. Cobertura de citação pergunta se uma resposta substantiva contém referência; relevância examina somente os trechos efetivamente citados. Assim, uma configuração pode recuperar evidência, deixar de citá-la e ainda ter P@5 alto, ou citar poucos casos muito fáceis e obter relevância alta sobre um denominador menor. No par de 512 tokens, acrescentar sobreposição aumenta a média de tokens de 3061 para 3095 e a latência de 10,8 para 11,3 s, sem recuperar o Recall@5 de 512/0. Nos pares de 128 e 256 tokens, a diferença de entrada é pequena diante da mudança de tamanho, indicando que o orçamento $k = 5$ é o principal determinante do volume entregue ao gerador.

Os julgamentos automáticos agregados indicam variação modesta de correção e fidelidade, mas não permitem decompor desfechos de modo válido sem as notas por item. A classificação revisada usa seis categorias respondíveis: resposta correta ou incorreta, cruzada com cobertura completa, parcial ou ausente. Perguntas não respondíveis são separadas em abstenção correta ou resposta inventada. Essa taxonomia registra dois fatos observáveis e evita chamar uma resposta errada com evidência presente de "falha de geração", pois o contexto pode ser ambíguo, a evidência pode estar truncada e a rubrica pode admitir discordância.

V. DISCUSSÃO E LIMITAÇÕES

Os resultados mostram um compromisso: slides ordenam a primeira evidência melhor, enquanto 512/0 cobre mais páginas ao custo de uma entrada maior e citações menos relevantes. O efeito da sobreposição não é consistente entre tamanhos nos agregados observados. Nenhuma dessas associações identifica, isoladamente, a causa de uma resposta incorreta. A análise corrigida deve descrevê-la como correta ou incorreta com cobertura completa, parcial ou ausente.

A evidência por página é um *proxy*: favorece a unidade slide no ranqueamento e pode contar uma janela longa como relevante mesmo que só parte do trecho sustente a resposta. Além disso, dois trechos sobrepostos podem cobrir a mesma página sem acrescentar evidência independente. Recall@5 por páginas reduz parte dessa duplicação, mas o orçamento continua sendo expresso em trechos; configurações longas recebem mais tokens sob o mesmo k. Portanto, a comparação controla o número de itens recuperados, não o orçamento total de tokens, e a tabela deve ser lida junto com o custo de entrada. Há múltiplas comparações, apenas 41 perguntas respondíveis, poucas perguntas multitrecho e um orçamento fixo de 5 trechos. As mesmas perguntas aparecem nas 7 configurações, exigindo análise pareada. A avaliação principal planejada usa somente 10 perguntas por configuração, em maioria respondíveis, e será feita pelos próprios autores; isso limita independência e poder estatístico mesmo após consenso. O estudo cobre um corpus, um modelo de *embedding* e um gerador de 3 bilhões de parâmetros. Os escores automáticos disponíveis podem compartilhar vieses e permanecem análise de sensibilidade [11]. O corpus é didático, visual e escrito em português; resultados podem mudar em textos corridos, documentos com seções longas ou bases em que a unidade semântica não coincide com uma página. O E5 foi usado sem ajuste ao domínio e o Qwen operou com um único *prompt*; uma conclusão sobre *chunking* não deve ser generalizada para recuperadores esparsos, reranqueadores ou geradores com outra janela e capacidade.

Há ainda um risco de seleção na construção das perguntas. Os autores conheciam os slides e anotaram as páginas de resposta, embora a divisão de desenvolvimento e teste tenha sido congelada antes da execução. Uma avaliação externa deveria revisar uma amostra das evidências, medir concordância sobre sua suficiência e repetir o teste em outro conjunto de aulas. Como várias métricas e configurações são examinadas, intervalos individuais de 95 % não controlam o erro familiar; os resultados são exploratórios e devem priorizar magnitudes e consistência dos pares, não a busca isolada por intervalos que excluem zero.

A. Reprodutibilidade e validade

Os manifestos registram os SHA-256 do corpus, do conjunto de perguntas, da seleção de k e do protocolo, além das revisões dos modelos e do commit da execução. O validador rejeita uma reconstrução se as 7 configurações, as 45 perguntas, os 315 pares ou o orçamento diferirem do experimento congelado. Resultados reconstruídos devem ser gravados em uma pasta nova para que tempo de execução, versões das bibliotecas e

eventuais diferenças de hardware permaneçam distinguíveis da execução original.

A amostra humana deve ser regenerada com a mesma semente e conter as 7 respostas para cada uma das 10 perguntas selecionadas. Os dois autores avaliam independentemente correção, completude e fidelidade em 0–2 e contam afirmações não sustentadas em 0–3, onde 3 significa três ou mais. Concordância exata e kappa ponderado são calculados antes de qualquer consenso; apenas divergências são expostas na planilha de resolução, ainda sem o identificador da configuração. Esse procedimento reduz contaminação entre julgamentos, mas não elimina o viés de autores que conhecem o corpus e formularam as perguntas.

As respostas podem repetir as mesmas perguntas entre configurações, logo observações não são independentes em uma análise não pareada. Da mesma forma, a relevância de citações tem tamanho efetivo variável: respostas abstidas ou sem citação válida não entram em seu denominador. Publicar as contagens elegíveis por configuração é necessário para interpretar diferenças nessa métrica e evitar que uma taxa mais alta reflita apenas um subconjunto mais fácil.

VI. Conclusão

Neste corpus e com Qwen2.5-3B-Instruct e $k = 5$, slides apresentaram MRR@5 de 0,87 e 512/0 Recall@5 de 0,94, acompanhados por custos de entrada e padrões de citação diferentes. A sobreposição de 20 % não mostrou vantagem observada consistente entre 128, 256 e 512 tokens. Esses resultados não sustentam que a segmentação estrutural seja suficiente, que o gerador seja o gargalo, ou que configurações sejam equivalentes. A conclusão definitiva sobre qualidade requer recuperar ou reconstruir os artefatos por pergunta e concluir a avaliação humana cega prevista.

Referências

[1] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, "Retrieval-augmented generation for knowledge-intensive NLP tasks," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459–9474.

[2] T. Chen, H. Wang, S. Chen, W. Yu, K. Ma, X. Zhao, H. Zhang, and D. Yu, "Dense X retrieval: What retrieval granularity should we use?" in *Proc. Conf. Empirical Methods Natural Lang. Process. (EMNLP)*, 2024, pp. 15 159–15 177.

[3] G. X. Evangelista and H. M. Ricardo, "Dataset de avaliação de RAG sobre aulas de inteligência artificial II," Zenodo, versão 1.0.0, 2026. [Online]. Available: https://doi.org/10.5281/zenodo.23986392

[4] V. Karpukhin, B. Oğuz, S. Min, P. Lewis, L. Wu, S. Edunov, D. Chen, and W.-t. Yih, "Dense passage retrieval for open-domain question answering," in *Proc. Conf. Empirical Methods Natural Lang. Process. (EMNLP)*, 2020, pp. 6769–6781.

[5] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, "Multilingual E5 text embeddings: A technical report," arXiv:2402.05672, 2024.

[6] L. Wang *et al.*, "multilingual-e5-base model card, revision d128750," Hugging Face, 2024, acesso em: 9 nov. 2026. [Online]. Available: https://huggingface.co/intfloat/multilingual-e5-base/tree/d128750597153bb5987e10b1c3493a34e5a4502a

[7] J. Johnson, M. Douze, and H. Jégou, "Billion-scale similarity search with GPUs," *IEEE Trans. Big Data*, vol. 7, no. 3, pp. 535–547, 2021.

[8] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, and P. Liang, "Lost in the middle: How language models use long contexts," *Trans. Assoc. Comput. Linguistics*, vol. 12, pp. 157–173, 2024.

[9] S. Es, J. James, L. Espinosa-Anke, and S. Schockaert, "RAGAS: Automated evaluation of retrieval augmented generation," in *Proc. 18th Conf. Eur. Chapter Assoc. Comput. Linguistics: System Demonstrations (EACL)*, 2024, pp. 150–158.

[10] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang, Z. Lin, Z. Li, D. Li, E. P. Xing, H. Zhang, J. E. Gonzalez, and I. Stoica, "Judging LLM-as-a-judge with MT-Bench and Chatbot Arena," in *Advances in Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track*, 2023.

[11] A. Panickssery, S. R. Bowman, and S. Feng, "LLM evaluators recognize and favor their own generations," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.

[12] F. A. Soares, "Inteligência artificial II: slides das aulas 14 a 23," Material didático da disciplina FGA0261, Universidade de Brasília, 2026.

[13] Qwen Team, "Qwen2.5 technical report," arXiv:2412.15115, 2024.

[14] ——, "Qwen2.5-3B-Instruct model card, revision aa8e725," Hugging Face, 2024, acesso em: 9 nov. 2026. [Online]. Available: https://huggingface.co/Qwen/Qwen2.5-3B-Instruct/tree/aa8e72537993ba99e69dfaafa59ed015b17504d1