Influência do Tamanho e da Sobreposição de *Chunks* na Recuperação e na Fidelidade de um Sistema RAG sobre Material Didático

Gustavo Xavier Evangelista
FCTE - Faculdade de Ciências e Tecnologias em Engenharia
Universidade de Brasília
Brasília, Brasil
Matrícula: 241025247
241025247@aluno.unb.br

Heitor Macêdo Ricardo
FCTE - Faculdade de Ciências e Tecnologias em Engenharia
Universidade de Brasília
Brasília, Brasil
Matrícula: 241039073
241039073@aluno.unb.br

***Resumo*—A segmentação do texto em trechos (*chunks*) é uma decisão de projeto de sistemas de geração aumentada por recuperação (RAG) quase sempre tomada por heurística. Este trabalho compara sete estratégias de segmentação sobre os slides de 10 aulas de Inteligência Artificial em português: um trecho por slide, como linha de base estrutural, e janelas de 128, 256 e 512 tokens com e sem 20 % de sobreposição. Com o modelo de *embedding*, o índice, o gerador e o *prompt* fixos, 315 pares configuração–pergunta foram avaliados sobre um conjunto de 45 perguntas de teste publicado com DOI. A segmentação por slide obteve o maior MRR@5 (0,87), enquanto a janela de 512 tokens obteve o maior Recall@5 (0,94) ao custo de cerca de três vezes mais tokens de contexto e quase o dobro da latência de geração. Nas métricas de recuperação, nenhuma diferença pareada contra a linha de base teve intervalo de confiança de 95 % afastado de zero; a exceção foi a precisão das citações, que caiu de 0,79 para 0,48 com trechos de 512 tokens. Todas as configurações se abstiveram corretamente nas perguntas sem resposta no material. Em uma amostra julgada por dois modelos de linguagem, as falhas de geração superaram as de recuperação, o que sugere que, neste corpus, a segmentação estrutural basta e o gargalo está no gerador.**

***Palavras-chave*—geração aumentada por recuperação, *chunking*, recuperação de informação, alucinação, modelos de linguagem**

I. Introdução

A geração aumentada por recuperação (RAG, do inglês *Retrieval-Augmented Generation*) condiciona um modelo de linguagem a trechos recuperados de uma base externa, o que permite responder com conhecimento atualizável e verificável [1]. Antes da indexação, os documentos precisam ser divididos em trechos (*chunks*), e essa divisão determina o que o recuperador consegue encontrar e o que o gerador chega a ler. Trechos pequenos tendem a ser precisos, mas fragmentam explicações; trechos grandes preservam contexto, mas diluem o sinal semântico e alongam o *prompt* [2], [3].

Material didático em slides é um caso particular: cada slide já é uma unidade semântica curta, o que sugere que a segmentação estrutural pode competir com janelas de tamanho fixo. A pergunta de pesquisa é: *como o tamanho e a sobreposição dos trechos influenciam a recuperação da evidência correta, o custo do contexto e a qualidade da resposta de um sistema RAG sobre slides de aula em português?*

Este trabalho contribui com: (i) a comparação de sete estratégias de segmentação sob protocolo idêntico, com a segmentação por slide como linha de base; (ii) um conjunto público de 45 perguntas de teste e 15 de desenvolvimento com evidência por página [4]; (iii) a separação entre falhas de recuperação e de geração, com intervalos de confiança por reamostragem.

II. Trabalhos Relacionados

Recuperação densa para RAG. O RAG original combinou um recuperador denso a um gerador *seq2seq* [1], apoiado na recuperação densa de passagens por codificadores duplos [5]. Modelos de *embedding* multilíngues, como o E5 [6], e bibliotecas de busca por similaridade, como o FAISS [7], tornaram esse arranjo reproduzível em português e em escala. Nesses trabalhos, a unidade de recuperação é tomada como dada, em geral passagens de tamanho fixo.

Granularidade da recuperação. Chen *et al.* [2] mostraram que a unidade indexada (passagem, sentença ou proposição) altera o desempenho da recuperação e da resposta. Liu *et al.* [3] observaram que modelos de linguagem usam pior a informação posicionada no meio de contextos longos, o que penaliza trechos grandes mesmo quando a evidência é recuperada.

Avaliação de RAG e alucinação. Alucinação é a geração de conteúdo sem apoio na fonte [8]; em RAG, mede-se a fidelidade da resposta ao contexto recuperado. O RAGAS [9] automatiza essa avaliação com modelos de linguagem, e o uso de modelos como juízes apresenta boa concordância com humanos, mas com vieses conhecidos [10], [11].

Diferentemente desses trabalhos, este estudo isola a segmentação em um corpus didático em português, compara janelas fixas contra a estrutura nativa dos slides e reporta a incerteza de cada diferença.

III. Metodologia

A. Corpus e conjunto de avaliação

O corpus são os slides em PDF das aulas 14 a 23 da disciplina [12], que cobrem processamento de linguagem natural e LLMs, aprendizado por reforço, explicabilidade e equidade, em 482 páginas. O texto foi extraído por página com PyMuPDF, com recomposição de acentos separados pelo LaTeX e remoção do rodapé repetido; cada página guarda aula, número e SHA-256 do arquivo de origem.

O conjunto de avaliação [4] tem 60 perguntas: 30 factuais, 15 contextuais, 10 que exigem múltiplos trechos e 5 sem resposta no corpus, com seis perguntas por aula. Cada pergunta tem resposta de referência e a lista de evidências válidas como pares (aula, página), e foi escrita por um autor e revisada pelo outro contra o texto extraído. A divisão em 15 perguntas de desenvolvimento e 45 de teste foi fixada antes de qualquer experimento; o teste foi lido uma única vez.

B. Estratégias de segmentação

A linha de base estrutural (`slide`) indexa cada página como um trecho. As seis janelas fixas combinam 128, 256 e 512 tokens com sobreposição de 0 ou 20 %, contadas no tokenizador do próprio modelo de *embedding*. As janelas não atravessam a fronteira entre aulas, e cada trecho registra o intervalo de páginas que cobre. Na configuração de 512 tokens, o prefixo do E5 e os tokens especiais podem levar a entrada a 516 posições, e o modelo trunca até quatro tokens finais; os manifestos dos índices contabilizam os trechos afetados.

C. Recuperação e geração

O modelo de *embedding*, comum a todas as configurações, é o E5 multilíngue base [6] em revisão fixa, com os prefixos `query:` e `passage:`, vetores normalizados e busca exata por produto interno (`IndexFlatIP`) [7]. O número de trechos passados ao gerador foi escolhido no desenvolvimento entre $k \in \{1, 3, 5\}$ pelo maior Recall médio, resultando em $k = 5$; como o Recall não decresce com k, a regra equivale a usar o maior orçamento de contexto considerado.

O gerador é o Qwen2.5-3B-Instruct [13] em revisão fixa, com decodificação gulosa, no máximo 256 tokens de resposta e precisão de 16 bits em uma GPU T4. O *prompt* delimita cada trecho por marcação com identificador, exige que cada afirmação cite o trecho que a sustenta e determina uma frase exata de abstenção quando o contexto não basta.

D. Métricas e justificativa

A métrica principal de recuperação é o Recall@k, a fração das páginas-evidência presentes entre os k trechos entregues ao gerador, porque uma evidência ausente do contexto não pode sustentar a resposta. O MRR@5 complementa o Recall por medir a posição da primeira evidência, relevante porque o gerador usa pior o que não está no início do contexto [3]. Um trecho é relevante quando seu intervalo de páginas contém uma página-evidência, e perguntas sem resposta ficam fora dessas métricas. Também foram medidas a Precision@5 e, nas perguntas que exigem múltiplos trechos, a fração com todas as evidências no top-5 (Multi@5). Na geração, mediram-se a abstenção correta nas perguntas sem resposta, a fração de respostas com citação, os tokens de contexto e a latência, que compõem o custo de cada configuração. Duas métricas automáticas cobrem todas as 315 respostas: a precisão de citação, fração dos trechos citados que contêm uma página-evidência, que mede se a resposta aponta para a fonte certa; e o F1 de tokens contra a resposta de referência, após remoção de acentos, citações e palavras vazias, um indicador grosseiro de correção que penaliza paráfrases.

A qualidade da resposta foi avaliada em uma amostra de 10 perguntas de teste, sorteadas com estratificação por categoria, sob as sete configurações (70 itens). Por falta de tempo para a avaliação humana prevista, os itens foram julgados por dois modelos de linguagem independentes (Claude Opus e Claude Sonnet), sem acesso à configuração, com uma rubrica de correção, completude e fidelidade de 0 a 2 e contagem de afirmações sem apoio no contexto. A concordância entre os juízes foi medida pelo kappa de Cohen com pesos quadráticos [14], e cada item respondível foi classificado como acerto, falha de recuperação (evidência fora do top-k) ou falha de geração (evidência recuperada e resposta incorreta), usando a menor nota dos dois juízes.

A semente 42 fixou o sorteio da amostra e as reamostragens, e as revisões dos modelos estão fixadas por *hash* no código. Como a decodificação é determinística, a dispersão vem das perguntas: os intervalos de confiança de 95 % são percentis de 10.000 reamostragens *bootstrap* das perguntas [15], e as diferenças contra a linha de base são pareadas por pergunta. O código, os manifestos com SHA-256 e o *commit* da execução estão em https://github.com/HeitorM50/IA2-2026.2.

IV. Resultados

A Tabela I resume as 7 configurações no teste.

A segmentação por slide teve o maior R@1 (0,72) e o maior MRR@5 (0,87, IC [0,77; 0,95]), e a janela de 512 tokens sem sobreposição teve o maior Recall@5 (0,94). As diferenças pareadas contra a linha de base foram pequenas diante da incerteza: a janela de 512 tokens ficou 0,06 acima em Recall@5 (IC [−0,01; 0,15]) e −0,10 em MRR@5 (IC [−0,21; 0,02]). O custo, por outro lado, separa as configurações com clareza: a janela de 512 tokens enviou em média 3061 tokens ao gerador, contra 1113 da segmentação por slide, e a latência de geração subiu de 6,1 para 10,8 s (Fig. 1).

Todas as configurações se abstiveram nas 4 perguntas sem resposta (100%) e nenhuma citou trecho inexistente. A fração de respostas com citação caiu para 82% na janela de 512 tokens com sobreposição, contra 95% na segmentação por slide. A precisão de citação separou as configurações com mais clareza: entre 254 respostas com citação, ela foi 0,79 (IC [0,66; 0,91]) com slides e 0,48 (IC [0,32; 0,64]) com janelas de 512 tokens sem sobreposição, uma diferença pareada de −0,31 (IC [−0,50; −0,12]), a única cujo intervalo exclui zero. O F1 de tokens ficou entre 0,26 e 0,31 em todas as configurações, sem diferença relevante contra a linha de base (por exemplo, −0,04, IC [−0,07; 0,00], para 512 tokens). Por parte

Tabela I

RECUPERAÇÃO, QUALIDADE DA RESPOSTA E CUSTO NO TESTE, POR CONFIGURAÇÃO (TAMANHO EM TOKENS / SOBREPOSIÇÃO). RECUPERAÇÃO, PREC. CIT. E F1 SOBRE 41 PERGUNTAS RESPONDÍVEIS; MULTI@5: PERGUNTAS DE MÚLTIPLOS TRECHOS COM TODAS AS EVIDÊNCIAS NO TOP-5; CIT.: RESPOSTAS COM CITAÇÃO; PREC. CIT.: TRECHOS CITADOS QUE CONTÊM EVIDÊNCIA; CORR. E FID.: CORREÇÃO E FIDELIDADE MÉDIAS DOS JUÍZES EM [0, 1], SOBRE 10 PERGUNTAS; TOK.: TOKENS DE CONTEXTO POR PERGUNTA; LAT.: LATÊNCIA DE GERAÇÃO. EM NEGRITO, O MELHOR VALOR DE CADA COLUNA.

Config.	Recuperação					Resposta					Custo	
	R@1	R@5	MRR@5	P@5	Multi@5	Cit.	Prec. cit.	F1	Corr.	Fid.	Tok.	Lat. (s)
Slide	**0,72**	0,88	**0,87**	0,22	0,50	95%	0,79	**0,31**	**0,70**	0,85	1113	6,1
128 / 0%	0,60	0,89	0,78	0,36	**0,62**	95%	0,76	0,27	0,65	0,82	**1033**	**5,6**
128 / 20%	0,65	0,91	0,81	**0,40**	0,50	95%	**0,80**	0,30	0,65	0,90	1035	6,2
256 / 0%	0,63	0,89	0,79	0,29	**0,62**	93%	0,71	0,31	0,68	**0,93**	1724	7,1
256 / 20%	0,60	0,93	0,80	0,35	**0,62**	**98%**	0,74	0,30	**0,70**	0,90	1735	6,8
512 / 0%	0,58	**0,94**	0,77	0,26	**0,62**	90%	0,48	0,28	0,62	0,88	3061	10,8
512 / 20%	0,60	0,89	0,77	0,33	**0,62**	82%	0,64	0,26	0,68	0,85	3095	11,3

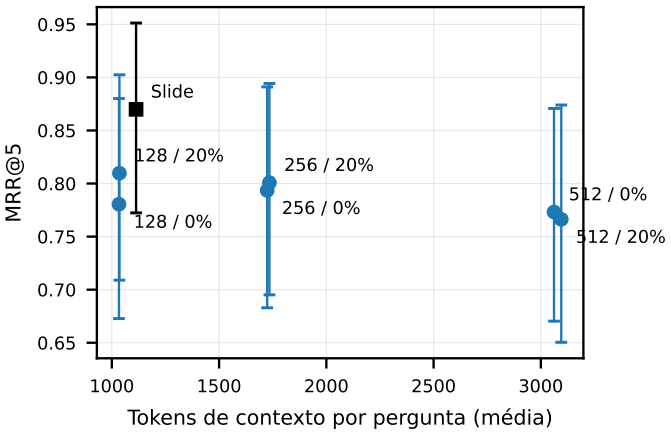


Fig. 1. MRR@5 contra o número médio de tokens de contexto por pergunta; barras indicam o IC de 95% por *bootstrap*. A linha de base por slide (quadrado) obtém a melhor ordenação com um dos menores custos.

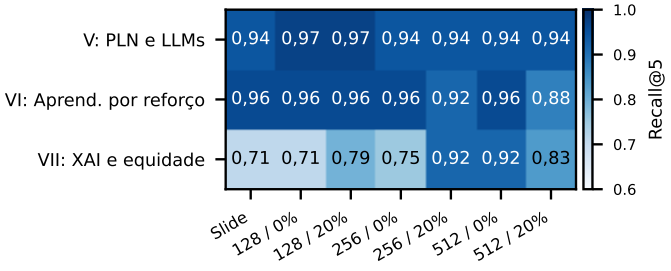


Fig. 2. Recall@5 por parte do curso e configuração. As janelas com sobreposição ou de 512 tokens recuperam melhor as evidências de explicabilidade e equidade (Parte VII).

do curso (Fig. 2), a maior diferença ocorreu em explicabilidade e equidade (Parte VII), onde o Recall@5 foi 0,71 com slides e 0,92 com janelas de 256 tokens com sobreposição; nas Partes V e VI, todas as configurações ficaram próximas do teto. Nas perguntas de múltiplos trechos, a cobertura completa das evidências subiu de 0,50 com slides para 0,62 com as janelas, sobre apenas oito perguntas.

Os juízes concordaram com kappa ponderado de 0,92 em

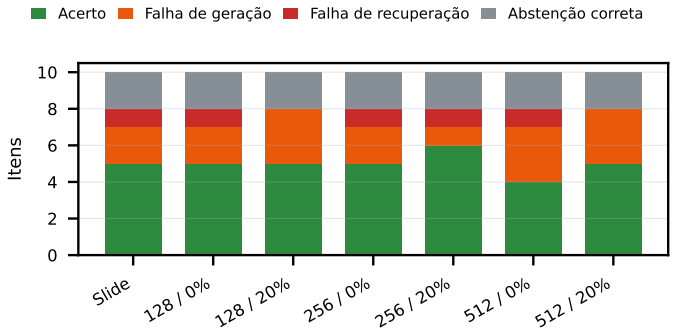


Fig. 3. Desfechos da amostra julgada (10 perguntas por configuração), com a menor nota dos dois juízes. As falhas de geração predominam sobre as de recuperação em todas as configurações.

correção e 0,82 em fidelidade, e as médias de correção variaram de 0,62 a 0,70 entre configurações. Dos 56 itens respondíveis da amostra, 35 foram acertos, 16 falhas de geração e 5 falhas de recuperação, e nenhuma resposta foi inventada para pergunta sem resposta (Fig. 3).

V. DISCUSSÃO E LIMITAÇÕES

A vantagem da segmentação por slide na ordenação é coerente com o material: cada slide condensa um conceito, e as perguntas factuais têm, por construção do conjunto, a resposta em uma única página, de modo que o trecho estrutural casa semanticamente com a pergunta. As janelas maiores ganham Recall@5 porque cada trecho cobre várias páginas e conta como relevante se qualquer uma delas for evidência, o que também explica a menor precisão e o custo maior. Na Parte VII, uma explicação provável é que conteúdos distribuídos por slides consecutivos, como as tabelas comparativas de métricas, sejam mais bem cobertos por janelas que unem páginas vizinhas. Com trechos de 512 tokens, o gerador citou menos e, quando citou, apontou mais vezes para um trecho sem a evidência, embora trechos longos tenham mais chance de conter a página certa; isso é compatível com a dificuldade de modelos pequenos em localizar informação em contextos longos [3] e afeta diretamente a verificabilidade da resposta.

Como as falhas de geração superaram as de recuperação na amostra, ampliar o contexto tende a ter retorno limitado, e a hipótese a testar é que um gerador maior tenha efeito maior que a troca de segmentação.

Exceto pela precisão de citação, o estudo não demonstra superioridade de nenhuma configuração: com 41 perguntas respondíveis, os intervalos das diferenças incluem zero ou tocam nele, e os resultados devem ser lidos como tendências. A evidência anotada por página favorece a segmentação por slide no MRR e as janelas longas no Recall, e as perguntas foram escritas pelos próprios autores a partir dos slides. A qualidade da resposta foi julgada por modelos de linguagem e não por humanos; juízes automáticos tendem a concordar entre si mais do que avaliadores humanos e podem compartilhar vieses [11], de modo que o kappa alto não garante validade, e a amostra de 10 perguntas não tem poder para comparar configurações. Por fim, o estudo usa um único corpus, um único gerador de 3 bilhões de parâmetros e uma execução determinística, e a regra de seleção de k fixou o maior valor candidato.

VI. Conclusão

Em slides de aula em português, a segmentação estrutural por slide recuperou a evidência nas primeiras posições tão bem quanto janelas de tamanho fixo e com um dos menores custos de contexto. Janelas longas aumentaram a cobertura das evidências, mas encareceram a geração e pioraram a precisão das citações, o que prejudica a verificação da resposta. O gargalo observado esteve mais no gerador do que na recuperação. Trabalhos futuros devem repetir o protocolo com mais perguntas, avaliação humana e geradores maiores.

Referências

[1] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, "Retrieval-augmented generation for knowledge-intensive NLP tasks," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459–9474.

[2] T. Chen, H. Wang, S. Chen, W. Yu, K. Ma, X. Zhao, H. Zhang, and D. Yu, "Dense X retrieval: What retrieval granularity should we use?" in *Proc. Conf. Empirical Methods Natural Lang. Process. (EMNLP)*, 2024.

[3] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, and P. Liang, "Lost in the middle: How language models use long contexts," *Trans. Assoc. Comput. Linguistics*, vol. 12, pp. 157–173, 2024.

[4] G. X. Evangelista and H. M. Ricardo, "Dataset de avaliação de RAG sobre aulas de inteligência artificial II," Zenodo, versão 1.0.0, 2026. [Online]. Available: https://doi.org/10.5281/zenodo.23986392

[5] V. Karpukhin, B. Oğuz, S. Min, P. Lewis, L. Wu, S. Edunov, D. Chen, and W.-t. Yih, "Dense passage retrieval for open-domain question answering," in *Proc. Conf. Empirical Methods Natural Lang. Process. (EMNLP)*, 2020, pp. 6769–6781.

[6] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, "Multilingual E5 text embeddings: A technical report," arXiv:2402.05672, 2024.

[7] J. Johnson, M. Douze, and H. Jégou, "Billion-scale similarity search with GPUs," *IEEE Trans. Big Data*, vol. 7, no. 3, pp. 535–547, 2021.

[8] Z. Ji, N. Lee, R. Frieske, T. Yu, D. Su, Y. Xu, E. Ishii, Y. J. Bang, A. Madotto, and P. Fung, "Survey of hallucination in natural language generation," *ACM Comput. Surv.*, vol. 55, no. 12, pp. 1–38, 2023.

[9] S. Es, J. James, L. Espinosa-Anke, and S. Schockaert, "RAGAS: Automated evaluation of retrieval augmented generation," in *Proc. 18th Conf. Eur. Chapter Assoc. Comput. Linguistics: System Demonstrations (EACL)*, 2024, pp. 150–158.

[10] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang, Z. Lin, Z. Li, D. Li, E. P. Xing, H. Zhang, J. E. Gonzalez, and I. Stoica, "Judging LLM-as-a-judge with MT-Bench and Chatbot Arena," in *Advances in Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track*, 2023.

[11] A. Panickssery, S. R. Bowman, and S. Feng, "LLM evaluators recognize and favor their own generations," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.

[12] F. A. Soares, "Inteligência artificial II: slides das aulas 14 a 23," Material didático da disciplina FGA0261, Universidade de Brasília, 2026.

[13] Qwen Team, "Qwen2.5 technical report," arXiv:2412.15115, 2024.

[14] J. Cohen, "Weighted kappa: Nominal scale agreement with provision for scaled disagreement or partial credit," *Psychological Bulletin*, vol. 70, no. 4, pp. 213–220, 1968.

[15] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. New York: Chapman & Hall, 1993.