

Plano de Ensino

Dados de Identificação	
Professor:	Fabiano Araujo Soares
Contato:	fabianosoaes@unb.br
Disciplina:	FGA0261 - Tópicos Especiais em Eletrônica
Turma:	T02
Semestre:	1º/2026
Horário:	3ª e 5ª às 18:00
Local:	Sala S7
Duração da aula:	1 hora e 50 minutos
Site do curso:	https://www.fabianosoaes.eng.br/fga0261-intelig%C3%A2ncia-artificial-ii

1 Descrição

Este curso representa uma imersão avançada no estado da arte do aprendizado de máquina, aprofundando os fundamentos de IA I para explorar arquiteturas de redes neurais convolucionais (CNNs), recorrentes (RNNs/LSTMs), transformers, autoencoders, grandes modelos de linguagem (LLMs), aprendizado por reforço profundo e IA generativa. Ao longo do semestre, os estudantes desenvolvem competências práticas e analíticas para projetar, treinar, avaliar e interpretar modelos complexos, abordando processamento de dados, otimização de hiperparâmetros, transfer learning, explicabilidade (XAI), fairness, accountability e aplicações em visão computacional, processamento de linguagem natural e sistemas autônomos.

A abordagem combina aulas expositivas, experimentação intensiva com PyTorch, análise de artigos científicos e apresentações críticas, com ênfase em formulação de hipóteses, validação rigorosa de resultados e reflexão sobre os limites e impactos éticos da IA moderna. Ao final do curso, o aluno estará preparado para conduzir pesquisas aplicadas, contribuir para publicações acadêmicas, implementar soluções de IA escaláveis e avaliar criticamente os avanços e riscos tecnológicos emergentes.

1.1 Objetivo Geral

Desenvolver no estudante uma visão crítica e aplicada das principais técnicas contemporâneas de Deep Learning, capacitando-o a projetar, treinar, avaliar e interpretar modelos avançados (CNNs, RNNs/LSTMs, autoencoders, modelos generativos, Transformers/LLMs e Deep RL), considerando também aspectos de explicabilidade, fairness e impacto social da IA.

1.2 Específicos

- Compreender os fundamentos teóricos e práticos de redes neurais profundas, incluindo MLPs, técnicas de regularização, pipelines de treinamento/validação e métricas de avaliação de modelos.

- Projetar, implementar e ajustar modelos de Deep Learning para dados espaciais e sequenciais (CNNs, RNNs/LSTMs), incluindo o uso de autoencoders e modelos generativos em aplicações típicas de visão computacional, séries temporais e redução de dimensionalidade.
- Entender a arquitetura Transformer e o funcionamento de Grandes Modelos de Linguagem (LLMs), explorando embeddings, estratégias básicas de adaptação (finetuning/LoRA) e padrões de prompt engineering para tarefas modernas de PLN.
- Aplicar conceitos de IA explicável, fairness e aprendizado por reforço profundo para analisar o comportamento de modelos, discutir impactos éticos e sociais da IA e conduzir pequenos experimentos empíricos com ferramentas modernas de Deep Learning.

1.3 Pré-requisitos

Disciplina Pré-requisito: FGA0221 – Inteligência Artificial e conhecimentos em Python. O aluno deve dominar fundamentos de IA clássica, programação em Python e noções básicas de aprendizado de máquina, pois a disciplina aprofunda técnicas modernas de Deep Learning, PLN, XAI e aprendizado por reforço profundo.

2 Ementa

1. Fundamentos de Deep Learning: Arquiteturas básicas, perceptron, multilayers, ativação e regularização. 2. Redes Neurais Convolucionais (CNNs): Estruturas, aplicações em visão computacional, transfer learning. 3. Redes Neurais Recorrentes e LSTMs: Modelagem temporal, processamento de sequências, aplicações em PLN. 4. Autoencoders e Redução de Dimensão: Teoria e prática de autoencoders, aplicações: compressão, remoção de ruído. IA Generativa: VAEs, GANs, geração de imagens/textos. 5. Grandes Modelos de Linguagem (LLMs): Transformers, embedding finetuning, prompt engineering, aplicações em texto. 6. Processamento de Linguagem Natural: Tarefas modernas (QA, sumário, tradução), contextos semânticos, BERT, GPT. 7. IA Explicável (XAI): LIME, SHAP, transparência, questões éticas e regulatórias. 8. Fairness e Accountability: Vieses e mitigação, análise de impacto social. 9. Aprendizado por Reforço Profundo: DQN, PPO, simulações, agentes em ambientes complexos.

3 Conteúdos

1. Fundamentos de Deep Learning

Arquiteturas básicas, perceptron, multilayers, ativação e regularização.

2. Modelos para visão e sequências

Redes Neurais Convolucionais (CNNs): Estruturas, aplicações em visão computacional, transfer learning, Redes Neurais Recorrentes e LSTMs, Modelagem temporal, processamento de sequências e aplicações em PLN.

3. Autoencoders, redução de dimensão e IA generativa

Autoencoders e Redução de Dimensão, Teoria e prática de autoencoders, aplicações: compressão e remoção de ruído. IA Generativa: VAE, GANs, geração de imagens/textos.

4. PLN moderno e Grandes Modelos de Linguagem

Grandes Modelos de Linguagem (LLMs), Transformers, embedding, finetuning, prompt engineering, aplicações em texto, Processamento de Linguagem Natural, Tarefas modernas (QA, sumário, tradução), contextos semânticos, BERT, GPT.

5. Aprendizado por reforço profundo

Aprendizado por Reforço Profundo: DQN, PPO, simulações, agentes em ambientes complexos.

6. IA explicável, ética e regulamentação

IA Explicável (XAI): LIME, SHAP, transparência, questões éticas e regulatórias, Fairness e Accountability, Vieses e mitigação, análise de impacto social.

4 Procedimentos metodológicos

O curso de Inteligência Artificial II será ministrado presencialmente, com aulas expositivas integradas a exemplos práticos em Python. Materiais didáticos serão disponibilizados no site do curso, e a comunicação entre professor e alunos ocorrerá preferencialmente pelo chat do grupo no Microsoft Teams. As avaliações serão entregues em datas definidas pelo professor, por meio do Microsoft Teams.

5 Recursos didáticos

O curso utilizará principalmente o site da disciplina e as plataformas Microsoft Office 365 da UnB tais como o Teams.

6 Avaliação

A avaliação da disciplina será baseada na elaboração de três artigos científicos, produzidos em grupos de dois alunos. Cada artigo deverá abordar uma temática distinta do curso, escolhida pelos próprios estudantes, e seguir o formato de artigos de congresso do IEEE, com no máximo quatro páginas. Os três artigos serão entregues em momentos distintos ao longo do semestre, conforme cronograma apresentado a seguir.

Todas as entregas devem ser realizadas exclusivamente pelo Microsoft Teams, dentro da pasta "Avaliações", na subpasta correspondente à atividade. Cada aluno deve criar, dentro dessa subpasta, uma pasta identificada com sua matrícula e nela incluir o material referente à atividade.

Para cada artigo, o grupo deverá selecionar um repositório público de dados (de pesquisa, didático ou gerado artificialmente), propor um projeto a partir desses dados, descrever a metodologia adotada para solucionar o problema, apresentar os resultados obtidos e discutir criticamente esses resultados, incluindo as limitações do trabalho. Os critérios de correção incluirão: o uso adequado de linguagem científica, a clareza na descrição da metodologia, a adequação das métricas ao problema proposto e a profundidade da análise apresentada na discussão e conclusão.

Os artigos poderão tratar de temas como:

I. Comparação entre algoritmos para um mesmo problema; II. Aplicação de algoritmos para solução de um problema proposto; III. Análise de explicabilidade (XAI) aplicada a um modelo treinado; IV. Estudo de viés e equidade (fairness) em modelos de aprendizado de máquina.

Ao final do curso, serão selecionados os melhores trabalhos para apresentação em sessão virtual gravada, na qual o professor avaliará as apresentações e os alunos também realizarão a avaliação dos trabalhos dos colegas, por meio de formulário fornecido pelo docente.

A nota final será composta da seguinte forma:

- 20% – Primeiro artigo;
- 25% – Segundo artigo;
- 25% – Terceiro artigo;
- 30% – Apresentação em sessão virtual gravada e formulários de avaliação pelos alunos.

7 Datas de Entrega das atividades

Atividade	Data de Entrega
Artigo 1	03/09/2026
Artigo 2	09/10/2026
Artigo 3	05/11/2026
Apresentações	A partir de: 08/12/2026

Tabela 1: Cronograma de Atividades

8 Controle de Presença

A lista de presença será disponibilizada em cada aula. O aluno deverá assinar a lista para obter presença na aula. Não serão aceitas assinaturas posteriores. **LEMBREM-SE QUE uma frequência inferior a 75% das aulas IMPLICA AUTOMATICAMENTE EM REPROVAÇÃO!** Não existe compensação de faltas.

9 Bibliografia

9.1 Referências Básicas

1. I. Goodfellow, Y. Bengio, A. Courville, **Deep Learning**, MIT Press, 1ª edição, 2016.
2. Chip Huyen, **AI Engineering**, O'Reilly Media, 1ª edição, 2025.
3. F. Chollet, **Deep Learning with Python**, Manning Publications, 2ª edição, 2021.
4. D. Jurafsky, J. H. Martin, **Speech and Language Processing**, Prentice Hall, 3ª edição (em preparação, rascunho online), 2023.
5. R. S. Sutton, A. G. Barto, **Reinforcement Learning: An Introduction**, MIT Press, 2ª edição, 2018.

9.2 Referências Complementares

1. W. Samek, G. Montavon, A. Vedaldi, L. K. Hansen, K.-R. Müller (eds.), **Explainable AI: Interpreting, Explaining and Visualizing Deep Learning**, Springer, 1ª edição, 2019.
2. L. Tunstall, L. von Werra, T. Wolf, **Natural Language Processing with Transformers**, O'Reilly Media, 1ª edição, 2022.

3. S. Barocas, M. Hardt, A. Narayanan, **Fairness and Machine Learning**, MIT Press, 1^a edição, 2023.
4. E. Stevens, L. Antiga, T. Viehmann, **Deep Learning with PyTorch**, Manning Publications, 1^a edição, 2020.
5. A. Rosebrock, **Deep Learning for Computer Vision**, PyImageSearch, 1^a edição, 2019.